



FACULTAD DE CIENCIAS MATEMÁTICAS Y FÍSICAS

Tema:

Métricas de evaluación

Título:

Comparación entre: Precisión, Recall, F1-Score y AUC-ROC

Autor:

Iván Andrés Moya Astudillo

Docente:

Ing. Darwin Alexander Rodríguez Merchán

Asignatura:

Aprendizaje Automático

Fecha de Inicio:

13 de Junio de 2026

Fecha de entrega:

13 de Junio de 2026

Comparación entre: Precisión, Recall, F1-Score y AUC-ROC

INTRODUCCIÓN:

La evaluación de modelos de clasificación es un paso determinante en cualquier proyecto de aprendizaje automático, ya que un modelo con alta exactitud aparente puede fallar en los aspectos que realmente importan según el contexto del problema. Cuando los datos están desbalanceados, o cuando un tipo de error es más grave que otro, como ocurre en el diagnóstico médico, es indispensable recurrir a métricas que vayan más allá de la exactitud global.

Este informe aborda el proyecto desarrollado en Google Colab "Evaluación y Optimización de Modelos de Clasificación", en el cual se entrenó un modelo de Regresión Logística sobre el conjunto de datos Breast Cancer de sklearn.datasets (569 muestras, 30 características) para distinguir tumores malignos y benignos. A partir de sus resultados, se comparan precisión, recall, F1-Score y AUC-ROC, se justifica cuál métrica resulta más adecuada para este caso, y se analizan los hallazgos sobre optimización de hiperparámetros y ajuste del umbral de decisión.

DESARROLLO:

Descripción General del Proyecto

El proyecto dividió el conjunto de datos en 80% para entrenamiento y 20% para prueba, con estratificación (455 y 114 muestras). Tras estandarizar las características, se entrenó una Regresión Logística, evaluada mediante matriz de confusión, métricas de clasificación, validación cruzada K-Fold ($k=5$ y $k=10$), búsqueda de hiperparámetros con GridSearchCV y RandomizedSearchCV, y un análisis del umbral de decisión.

Comparación entre Precisión, Recall, F1-Score y AUC-ROC

Cada métrica evalúa un aspecto distinto del desempeño. La precisión indica cuántos de los casos clasificados como positivos (benignos) lo son realmente, mientras que el recall indica qué proporción de los positivos reales fueron correctamente identificados. El F1-Score es la media armónica entre ambas y resulta útil cuando se busca equilibrio entre falsos positivos y falsos negativos. El AUC-ROC, en cambio, no depende de un umbral específico: mide la capacidad del modelo para discriminar entre clases en todos los umbrales posibles, lo que lo hace valioso en contextos médicos con clases desbalanceadas.

En el proyecto, el modelo base obtuvo los siguientes resultados sobre el conjunto de prueba:

Métrica	Resultado en el modelo base	Interpretación general
Precisión	0.9726 (97.26%)	De los casos clasificados como benignos, el 97.26% lo son realmente.
Recall	0.9861 (98.61%)	De todos los casos benignos reales, el modelo identificó correctamente el 98.61%.
F1-Score	0.9793 (97.93%)	Media armónica entre precisión y recall; refleja un balance global entre ambas.
AUC-ROC	0.9977 (99.77%)	Capacidad del modelo para distinguir entre clases en todos los umbrales posibles.

Estos resultados muestran un desempeño elevado en las cuatro métricas. Sin embargo, la diferencia entre falsos positivos (2) y falsos negativos (1) evidencia que, aunque precisión y recall son cercanos en valor numérico, su significado clínico es distinto: el falso negativo representa un caso maligno no detectado, un escenario de alto riesgo.

Métrica más adecuada

En este proyecto, la clase positiva (1) corresponde a "benigno" y la negativa (0) a "maligno". El costo de un falso negativo (tumor maligno clasificado como benigno) es mucho mayor que el de un falso positivo, pues implicaría que un paciente con cáncer no reciba tratamiento oportuno. Por ello, el recall de la clase maligna resulta especialmente relevante; sin embargo, optimizarlo en exceso puede generar demasiados falsos positivos, traducándose en procedimientos innecesarios para pacientes sanos.

Por ello, el AUC-ROC se presenta como la métrica más adecuada para evaluar el modelo de forma global, ya que resume su comportamiento en todos los umbrales posibles y no depende de un punto de corte fijo. Un AUC-ROC de 0.9977 indica una capacidad casi perfecta para ordenar correctamente los casos según su probabilidad de ser benignos o malignos. Se propone entonces un enfoque complementario: usar el AUC-ROC como criterio principal de comparación entre modelos, y ajustar después el umbral en función del recall de la clase maligna, priorizando detectar la mayor cantidad de casos positivos sin sacrificar demasiado la precisión.

CONCLUSIONES

RandomizedSearchCV resultó más eficiente en tiempo de ejecución que GridSearchCV, pues este último evaluó exhaustivamente las doce combinaciones posibles de C y solver, mientras

que RandomizedSearchCV exploró solo veinte combinaciones muestreadas de una distribución continua para C. Como el espacio de búsqueda era reducido, ambos métodos lograron resultados de F1-Score y AUC-ROC muy similares, lo que sugiere que, en espacios pequeños, la ventaja de RandomizedSearchCV no se traduce en una mejora sustancial de desempeño, aunque sí en ahorro de tiempo de cómputo.

En cuanto al efecto del ajuste del umbral sobre precisión y recall, los resultados mostraron una relación claramente inversa entre ambas métricas. Con un umbral bajo de 0.20, el recall alcanzó su valor máximo (1.0000): el modelo identificó todos los casos benignos del conjunto de prueba, pero la precisión bajó a 0.9114. Al subir el umbral hacia 0.70 y 0.80, la precisión mejoró hasta 0.9851, pero el recall cayó hasta 0.9167, señal de que el modelo se volvió más conservador al clasificar un caso como benigno. El F1-Score alcanzó su máximo (0.9796) en un punto intermedio, en el umbral óptimo de 0.55, cercano al umbral por defecto de 0.50. Esto confirma que no existe un umbral universalmente óptimo, sino que su elección depende del equilibrio que se busque entre falsos positivos y falsos negativos según las consecuencias prácticas de cada tipo de error.

Finalmente, este proyecto permitió comprender que la elección de una métrica de evaluación no es un paso meramente técnico, sino una decisión que debe estar alineada con el problema que se intenta resolver y con las consecuencias reales de cada tipo de error. Si bien la exactitud y el AUC-ROC ofrecieron una visión general sólida del desempeño, fue el análisis conjunto de la matriz de confusión, el recall y la curva de precisión-recall lo que permitió identificar que, en un contexto de diagnóstico médico, un solo falso negativo puede tener una importancia mucho mayor que su peso numérico dentro de las métricas globales. De igual manera, se aprendió que la validación cruzada K-Fold, la búsqueda de hiperparámetros y el ajuste del umbral no deben emplearse de forma aislada, sino como pasos complementarios que permiten construir un modelo no solo preciso en términos estadísticos, sino también responsable y adecuado para el contexto en el que será aplicado.

LINK PROYECTO EN GITHUB:

https://github.com/Ivn5739/Metrica_Evaluacion_Breast_Cancer/tree/main

REFERENCIAS

- Arxiv. (2020). *Arxiv*. Obtenido de Performance Analysis and Comparison of Machine and Deep Learning Algorithms for IoT Data Classification: <https://arxiv.org/pdf/2001.09636>
- Deepchecks. (2025). *Deepchecks*. Obtenido de Understanding F1 Score, Accuracy, ROC-AUC & PR-AUC Metrics: <https://deepchecks.com/f1-score-accuracy-roc-auc-and-pr-auc-metrics-for-models/>
- GeeksforGeeks. (2026). *GeeksforGeeks*. Obtenido de Comparing Randomized Search and Grid Search for Hyperparameter Estimation in Scikit Learn: <https://www.geeksforgeeks.org/machine-learning/comparing-randomized-search-and-grid-search-for-hyperparameter-estimation-in-scikit-learn/>
- KDnuggets. (2023). *KDnuggets*. Obtenido de Hyperparameter Tuning: GridSearchCV and RandomizedSearchCV, Explained. : <https://www.kdnuggets.com/hyperparameter-tuning-gridsearchcv-and-randomizedsearchcv-explained>
- Medrxiv. (2025). *Medrxiv*. Obtenido de A Fast and Interpretable Logistic Regression Framework for Breast Tumor Classification Using the Wisconsin Diagnostic Dataset.: <https://www.medrxiv.org/content/10.64898/2025.12.23.25342946v1>
- Research Square. (2025). *Research Square*. Obtenido de Machine Learning-based Breast Cancer Classification Using Logistic Regression and Random Forest: <https://www.researchsquare.com/article/rs-7638704/v1>
- Scikit-learn. (2026). *Scikit-learn*. Obtenido de Tuning the hyper-parameters of an estimator.: https://scikit-learn.org/stable/modules/grid_search.html.
- Thecodinggopher. (2026). *Thecodinggopher*. Obtenido de Precision vs. Recall vs. F1 Score vs. ROC-AUC. : <https://thecodinggopher.substack.com/p/precision-vs-recall-vs-f1-score-vs>